PINN Optimization:
Preliminary Experiments and Research Ideas

Curvature-Guided Adaptive Curriculum Optimization

2026-11-01 | 单种子预实验与待验证构想；不主张新颖性或已验证收益。

Research Motivation | 研究动机

PDE 微分算子可能导致残差优化病态 [5]；PDE 与初边值约束的 Jacobian/曲率结构不同，梯度方向也可能冲突。问题不只在于如何下降总损失，还在于如何保留已经满足的物理约束。本文汇总已有预实验，并提出一个尚未实现的方向曲率诊断构想。

Existing Optimization Methods | 方法分类

类别 / 代表方法	主要作用与代价	仓库实际记录
一阶自适应：Adam / AdamW [1,2]	逐参数矩统计，更新成本低	Adam 已测；AdamW 未测
拟牛顿：BFGS / L-BFGS [3]	割线曲率与线搜索；closure 可重复	L-BFGS、Adam→L-BFGS 已测
二阶/残差：GN、LM、Newton-CG、NNCG [4,5]	GN用 J⊡J；Newton-CG/NNCG用HVP/CG	仅阻尼 GN/LM* 已测，其余未测
结构化预条件：Shampoo / SOAP [6,7]	分层矩阵统计与基变换；非完整Hessian	SOAP* 已测；Shampoo 未单测
多目标方向：ConFIG / DCGD [8,9]	协调冲突梯度；需多任务梯度	ConFIG+GD、DCGD-Center+GD 已测
加权 / 课程：ReLoBRaLo、课程学习 [10,11]	调权或改变训练任务/难度	ReLoBRaLo、固定/规则顺序已测

另测SGD+Momentum、RMSProp、MultiAdam、PCGrad。*为教学性自实现核心，非官方完整实现复现。

Preliminary Experiments | 已完成的对照

主表为二维稳态热传导 −ΔT=q：单位方域、零 Dirichlet；T*=sin(πx)sin(πy)+0.2sin(3πx)sin(2πy)。2-24-24-1 tanh（697 参数），内点128、边界64；Lf为除以2π²后的PDE残差MSE，Lbc为边界MSE，等权。CPU单线程float64、seed=42、同初始化/采样，均1200外层步。[E2]

方法	最终 Lf+Lbc	相对 L² (%)	更新秒	循环wall秒	外层步
Adam	4.176e-03	2.55163	4.35	5.13	1200
L-BFGS	1.093e-05	0.10238	12.60	13.47	1200
Adam → L-BFGS	2.019e-05	0.20731	8.89	9.80	1200
SOAP*	1.096e-05	0.19560	6.16	7.13	1200
GN/LM*	8.454e-11	0.00311	96.37	97.22	1200

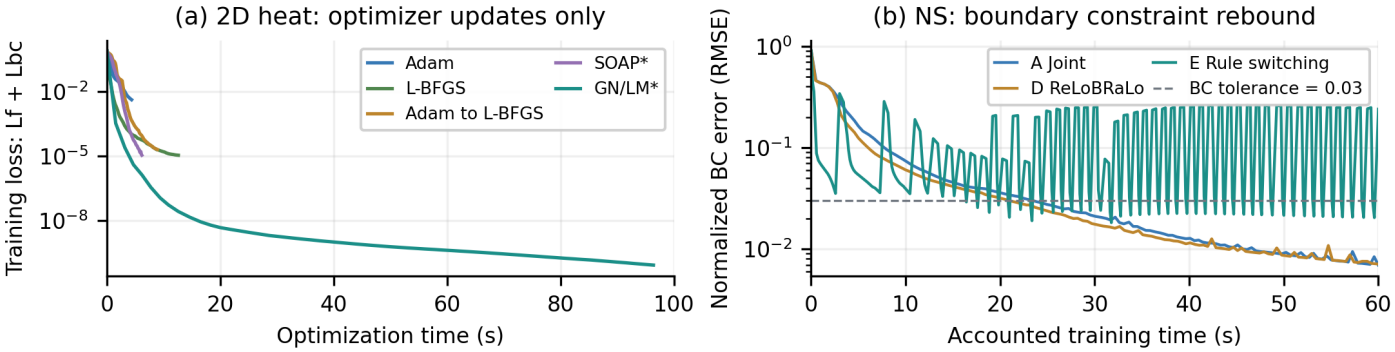


图1 真实检查点。(a) 上表数据，更新秒不含诊断。(b) NS Re=20、2307参数、内点256/BC128，Adam lr=.001，K=50；计费秒含诊断/策略，循环wall约61–62秒。两图计时口径不同。[E2,E4]

Key Observations | 结论与证据边界

1. 精度/成本：二维热传导LM终点耗时为SOAP的15.6倍；一维对应36.4倍 [E1,E2]。但首次记录达到1%误差，LM/L-BFGS/SOAP分别为3.18/2.87/3.85秒；仅LM达到0.1%（4.68秒）。等步终点比不能当等精度效率比；GN/LM是同一阻尼实现。

2. 耗时归因尚缺证据：代码每轮用jacrev显式构造J，再构造Gram、稠密求解并试探阻尼；热2D J为192×697、1D为272×697。没有分段profile，不能断言Jacobian或solve主导；没有GPU显存记录。

3. 损失下降不等于物理成功：二维载荷反演LM的训练平衡MSE约1.19e-12，但留出点为1.00e-2；圆柱接触的有限主结果压力误差约94%–98%，尚未成功 [E2,E3]。

4. 调度负结果：等60秒计费预算下，热传导E/A/D误差为0.198%/0.535%/0.064%；NS速度为22.03%/0.639%/0.682%。E切换95次，末e_bc=0.24；当前规则未胜过强基线，失败原因需消融 [E4]。

单种子、方法学习率不同且未等量调参；不支持普遍排名或显著性推断。完整配置、全部方法与来源见 experiment_evidence.md。

Research Question | 待检验的问题

能否仅用少量方向曲率，判断下一阶段应学 PDE、BC 还是 Joint，并降低已满足约束的退化风险，而不执行完整 GN/LM？目标选择在形式上可视为离散权重/切换控制；不能仅以“动态选任务”主张新颖性，相关加权与课程研究已存在 [10,11]。

Mathematical Motivation | 核心数学依据

令下标 i 表示物理约束块，n 为参数数、m_i 为残差数。残差按固定物理尺度归一化，并吸收 MSE 的样本数与固定权重，使以下平方范数与代码损失一致。

$$\theta \in \mathbb{R}^n, \quad r_i \in \mathbb{R}^{m_i}, \quad J_i = \frac{\partial r_i}{\partial \theta} \in \mathbb{R}^{m_i \times n}, \quad \mathcal{L}_i = \frac{1}{2}\|r_i\|_2^2, \quad g_i = J_i^\top r_i$$

$$\Delta\mathcal{L}_i \approx g_i^\top d + \frac{1}{2}\|J_i d\|_2^2$$

GN 忽略残差加权的二阶导数项，一般只是局部近似：残差或步长大时可能失准。边界残差恰为零且映射足够光滑时，下式成立；仅当更新方向不在边界 Jacobian 的零空间中，二次项才严格为正。这是已知最小二乘结构，不是新定理。

$$r_{bc} = 0 \implies g_{bc} = 0, \qquad \Delta\mathcal{L}_{bc} = \frac{1}{2}\|J_{bc} d\|_2^2 + O(\|d\|_2^3)$$

Preliminary Algorithm Idea | 曲率辅助选目标（构想）

固定基础优化器；从同一 Adam/SOAP 状态模拟 PDE、BC、Joint 三种有符号候选方向，未接受前不提交动量。以正步长缩放得到候选更新，对归一化物理探针上的各约束，预测改善量为：

$$d_a = \alpha_a p_a, \quad \hat{l}_i(a) = -\alpha_a g_i^\top p_a - \frac{\alpha_a^2}{2}\|J_i p_a\|_2^2, \quad a \in \{\text{PDE}, \text{BC}, \text{Joint}\}$$

1. 触发诊断：每 K 步或约束下降停滞/接近阈值时，估计状态；第一版不用控制器网络。

2. 风险守护：用线性化残差按分量检查已满足约束的容许阈值；在可行候选中按预测收益/预计总成本排序。无可行候选则缩短步长并检查 Joint/BC；小梯度不能替代可行性判断。

3. 检验并更新：试探一步，用实际/预测下降比检验局部模型，借鉴 LM/信赖域缩放 α；接受后提交优化器状态。一个方向的预测不保证随后 K 步，须限制执行窗口并重新检查。

只计算方向JVP，不形成完整Jacobian或Hessian；三候选×两类约束最多需6个分块JVP/次诊断。PINN残差含空间导数，JVP可能涉及较高阶混合求导；触发、候选生成、回退、探针与动量状态成本都须计入，效率收益尚未验证。

Planned Experiments | 下一轮计划，不是已完成结果

已有单种子A–E提供动机；以下按新协议重跑，并新增曲率与步长消融。

对照（全部为未来计划）	固定设置与主要辨别目标
① 固定权重 Adam / SOAP；② BC→PDE→Joint	基础解法与精调阶段长度基线；两种优化器分开比较
③ ReLoBRaLo；④ 仅一阶信息的目标调度	一阶调度使用损失进展、梯度及相同候选/守护检查
⑤ GN-JVP曲率目标调度；⑥ GN仅调步长	⑤与④检验曲率增量；⑤与⑥区分选任务和调步长

H1：在BC近满足处，对比一阶/GN对边界反弹的预测误差、校准与风险排序；H2：固定候选、步长控制及调参预算，用④⑤⑥区分选目标与调步长的收益；H3：包含全部诊断与回退，比较达到预注册精度的墙钟耗时。

先用二维热传导与Re=20 Kovasznay NS，固定网络/采样/验证点，5个共同种子、每组120秒端到端训练预算。到达目标须解/速度相对$L^2 \le 1\%$且$e_{bc} \le .03$；未达记删失。报告PDE/BC loss、Time-to-target、wall、反弹峰值/超阈次数、调度成本；H3另用免额外诊断基线，分项profile Jacobian/JVP、Gram、solve与回退，并做K/最小驻留消融。

References | 已核实的正式文献

[1] Kingma & Ba. Adam: A Method for Stochastic Optimization. ICLR, 2015.
[2] Loshchilov & Hutter. Decoupled Weight Decay Regularization. ICLR, 2019.
[3] Liu & Nocedal. On the limited memory BFGS method for large scale optimization. Math. Program. 45:503-528, 1989.
[4] Marquardt. An Algorithm for Least-Squares Estimation of Nonlinear Parameters. J. SIAM 11:431-441, 1963.
[5] Rathore et al. Challenges in Training PINNs: A Loss Landscape Perspective. ICML, 2024.
[6] Gupta et al. Shampoo: Preconditioned Stochastic Tensor Optimization. ICML, 2018.
[7] Vyas et al. SOAP: Improving and Stabilizing Shampoo using Adam for Language Modeling. ICLR, 2025.
[8] Liu, Chu & Thuerey. ConFIG: Towards Conflict-Free Training of Physics Informed Neural Networks. ICLR, 2025.
[9] Hwang & Lim. Dual Cone Gradient Descent for Training Physics-Informed Neural Networks. NeurIPS, 2024.
[10] Bischof & Kraus. Multi-Objective Loss Balancing for Physics-Informed Deep Learning. CMAME 439:117914, 2025.
[11] Krishnapriyan et al. Characterizing possible failure modes in physics-informed neural networks. NeurIPS, 2021.

证据标识：[E1] 1D demo；[E2] 2D baseline；[E3] Hertz kkt_all11；[E4] scheduler60。绝对路径、原始数值、缺失项及复核日志见随附 experiment_evidence.md。